



Universidad
Nacional
de Loja

Universidad Nacional de Loja

Facultad de la Energía, las Industrias y los Recursos Naturales
No Renovables

Carrera de Computación

Preguntas de investigación y objetivos aplicando
criterios SMART, verificando coherencia interna..

Research questions and objectives applying SMART
criteria, verifying internal consistency..

Metodología de la Investigación en
Computación.

AUTOR:

Ana Cristina Panamito Flores

TUTOR:

Prof. Luis Chamba-Eras

Loja, Ecuador

2026

Declaración de uso de IA Generativa

Yo, **Ana Cristina Panamito Flores**, en calidad de autor, declaro de manera transparente y responsable el uso de herramientas de Inteligencia Artificial Generativa (IAG) durante el desarrollo del presente trabajo, en conformidad con los principios de integridad académica, ética investigativa y buenas prácticas en el uso de tecnologías emergentes.

1. Alcance del uso de IA generativa

El uso de herramientas de IAG se ha limitado a funciones de apoyo, sin sustituir el juicio crítico ni la autoría intelectual del autor. En particular, se han utilizado para:

- Mejora de redacción y estilo académico.
- Generación de ideas preliminares.
- Apoyo en la estructuración del documento.
- Asistencia en traducción técnica.

2. Clasificación del uso según GAIDeT

De acuerdo con la taxonomía GAIDeT, el uso de IA generativa en este trabajo se clasifica en:

- **Nivel 1 – Asistencia Lingüística:** Corrección gramatical y mejora de claridad.
- **Nivel 2 – Apoyo en Ideación:** Generación de ideas y esquemas conceptuales.
- **Nivel 3 – Asistencia Técnica:** Apoyo en generación de código y explicaciones técnicas.

No se ha utilizado IA generativa para la generación autónoma de resultados ni para sustituir el análisis crítico del autor.

3. Validación y responsabilidad

Todo contenido asistido por IA ha sido revisado, validado y adaptado por el autor, quien asume la responsabilidad total sobre la calidad, veracidad y originalidad del trabajo.

4. Herramientas utilizadas

Se emplearon modelos de lenguaje (LLMs) y herramientas de asistencia técnica para redacción, estructuración y apoyo conceptual.

5. Consideraciones éticas

El uso de IA se realizó respetando principios de honestidad académica, normativas institucionales de la Universidad Nacional de Loja y buenas prácticas internacionales.

6. Declaración final

Declaro que el uso de IA generativa ha sido ético, transparente y complementario, sin comprometer la autoría ni la integridad académica del presente trabajo.

Loja, Ecuador, 5 mayo de 2026

Ana Cristina Panamito Flores
Autor

Preguntas de Investigación

1. ¿De qué manera la reducción de dimensionalidad mediante PCA influye en la eficiencia computacional (tiempo de entrenamiento) y en la precisión predictiva de modelos híbridos aplicados a entornos de computación perimetral (edge computing)?

Optimizar un modelo de predicción multivariada (ej. PCA-RVM) para reducir el tiempo de procesamiento en milisegundos y disminuir el error (MAE/RMSE) en al menos un 10 % comparado con modelos tradicionales

2. ¿Cómo mejora el uso de optimizaciones en manifolds de Grassmann y normas fraccionarias (L_p -norm) la robustez de la PCA frente a la presencia de valores atípicos (outliers) que distorsionan la extracción de componentes principales en señales biomédicas e imágenes?

Implementar el algoritmo GrIP-PCA para extraer componentes principales que ignoren eficazmente los efectos de un 10-16 por ciento de ruido/outliers en el dataset, logrando una varianza explicada superior a la de la PCA tradicional (L_2) en pruebas de reconstrucción de datos

3. ¿En qué medida la combinación de PCA suavizado y Escalamiento Multidimensional (MSSPD) permite preservar el ranking de distancias genéticas globales en mapas 2D, superando las limitaciones de colapso de subestructuras presentes en técnicas como t-SNE o UMAP?

Diseñar un flujo de visualización que seleccione automáticamente componentes principales que retengan más del 85 por ciento de la información crítica, reduciendo el error de clasificación (CE) en subpoblaciones y manteniendo la jerarquía de distancias del espacio de alta dimensión en la representación visual

Objetivo General

Evaluar la efectividad del Análisis de Componentes Principales (PCA) y sus variantes avanzadas en la reducción de la dimensionalidad de datos complejos, con el

fin de optimizar la precisión predictiva y la eficiencia computacional de modelos de aprendizaje automático aplicados a la salud, la energía y el monitoreo ambiental

Objetivos Específicos

1. Reducción de Redundancia: Seleccionar componentes principales que retengan entre el 85 por ciento y el 95 por ciento de la varianza explicada original para eliminar la colinealidad en variables meteorológicas y oceánicas, reduciendo así la carga de entrenamiento en modelos híbridos como PCA-RVM o PCA-GRNN

2. Robustez ante Ruido: Implementar optimizaciones de PCA basadas en normas fraccionarias (L_p -norm) y manifolds de Grassmann (como GrIP-PCA) para garantizar que la extracción de características sea resistente a valores atípicos (outliers) que representen entre el 10 por ciento y 16 por ciento del ruido en datasets de imágenes y señales biomédicas

3. Preservación de Estructura Global: Diseñar un flujo metodológico que integre PCA suavizado con Escalamiento Multidimensional (MSSPD) para preservar el ranking de distancias globales en la visualización de estructuras poblacionales, superando la tendencia al colapso de subpoblaciones que presentan técnicas no lineales

article

[utf8]inputenc [spanish]babel [a4paper,margin=2.5cm]geometry

Clasificación y Análisis de Literatura Científica sobre PCA

A. Antecedentes (Bases Teóricas y Fundacionales)

Estos artículos proporcionan el marco teórico clásico de PCA y las métricas de validación que sirven de base para estudios modernos.

- **Source 5 y Source 17:** Presentan tutoriales y revisiones sobre la naturaleza lineal de PCA, su dependencia de la varianza y su formulación matemática basada en autovectores y autovalores.
- **Source 16:** Explica el uso histórico de PCA en genética para analizar estructuras poblacionales mediante representaciones bidimensionales.
- **Source 11:** Describe aplicaciones tradicionales de PCA en procesos de búsqueda rápida de libros de códigos dentro de técnicas de cuantización vectorial.

B. Estado del Arte (Innovaciones y Métodos Actuales 2020-2025)

Artículos que proponen variantes avanzadas o modelos híbridos para superar las limitaciones de la PCA tradicional.

- **Source 7 (GrIP-PCA):** Introduce una variante robusta basada en optimización sobre manifolds de Grassmann y normas L_p para manejar datos con valores atípicos.
- **Source 3 (PCA + Residual Learning):** Combina PCA con aprendizaje residual para interpretar escenas hiperespectrales complejas.
- **Source 18 (CellMentor):** Critica la sensibilidad de PCA frente al ruido técnico en datos biológicos (*scRNA-seq*) y propone métodos basados en NMF que preservan mejor la identidad celular.
- **Source 20:** Realiza una comparación masiva entre 30 métodos de reducción de dimensionalidad, evaluando el desempeño de PCA frente a técnicas modernas como t-SNE y UMAP.

C. Trabajos Relacionados (Aplicaciones Específicas)

Investigaciones que utilizan PCA como herramienta de soporte en diferentes dominios.

- **Salud:** Predicción de salud fetal (Source 14) y análisis de pupilometría (Source 17).
- **Energía y Medio Ambiente:** Pronóstico fotovoltaico (Source 2), monitoreo de calidad del agua oceánica (Source 10) y detección de fugas (Source 9).
- **Seguridad y SAR:** Detección de intrusos en IoT (Source 22) y eliminación de ruido en imágenes radar SAR (Source 8 y Source 15).

2. Clasificación por Importancia

Rango de Importancia	Artículos Clave	Justificación de Validación
Mayor Importancia (Alta Rigurosidad)	Sources 5, 6, 7, 14, 18, 20	Presentan comparativas empíricas, métricas de error precisas (MAE, F1-score) y solucionan problemas relacionados con ruido y preservación de estructuras globales.
Importancia Media (Aplicaciones Útiles)	Sources 2, 3, 4, 10, 16, 19	Validan la eficacia de PCA en entornos reales como energía, agricultura y genética, además de mejorar el rendimiento de otros algoritmos como XGBoost o RVM.
Menor Importancia (Muy Específicos)	Sources 8, 9, 11, 12, 15, 22	Se enfocan en aplicaciones de nicho como radar SAR, vibraciones táctiles o búsqueda de códigos, con menor capacidad de generalización teórica.

3. Elementos que No Corresponden a Artículos Científicos

- **Source 1 (Imagen):** Corresponde a una captura de pantalla utilizada como plantilla metodológica para organizar información.
- **Source 13 (Word):** Es un documento de apoyo para describir problemas técnicos y no contiene investigación científica propia.

Nota: Ambos documentos son útiles como herramientas de trabajo, pero no deben considerarse dentro del conjunto de literatura científica analizada.

4. Validación de los Artículos

Los artículos seleccionados presentan validez académica por las siguientes razones:

- **Publicaciones Indexadas:** La mayoría fueron publicados en revistas reconocidas como IEEE Access, Nature Scientific Reports y revistas especializadas en sistemas inteligentes y análisis de datos, garantizando revisión por pares.

- **Recencia:** El período de publicación entre 2020 y 2025 asegura que la información corresponde a investigaciones actuales.
- **Consistencia de Resultados:** Diferentes investigaciones coinciden en que PCA destaca por su eficiencia computacional y reducción de colinealidad, aunque presenta limitaciones frente a técnicas no lineales como UMAP y t-SNE.

Referencias bibliográficas

- [1] M. A. Talukder, M. Khalid, and N. Sultana, “A hybrid machine learning model for intrusion detection in wireless sensor networks leveraging data balancing and dimensionality reduction,” *Scientific Reports*, vol. 15, 12 2025.
- [2] L. Ge, Y. Xian, J. Yan, B. Wang, and Z. Wang, “A hybrid model for short-term pv output forecasting based on pca-gwo-grnn,” *Journal of Modern Power Systems and Clean Energy*, vol. 8, pp. 1268–1275, 11 2020.
- [3] S. Kim, S. H. Chu, Y. J. Park, and C. Y. Lee, “A tied-weight autoencoder for the linear dimensionality reduction of sample data,” *Scientific Reports*, vol. 14, 12 2024.
- [4] A. Almadhor, A. AlHejaili, A. Alqahtani, N. Ghazouani, B. Bouallegue, V. Karovič, and S. Abbas, “Advanced hyperspectral scene interpretation through pca-enhanced residual learning in complex spectral domains,” *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2026.
- [5] M. Bhatti, Z. Zeeshan, S. Ms, U. Bhatti, A. Khan, Y. Y. Ghadi, S. Alsenan, Y. Li, M. Asif, and T. Afzal, “Advanced plant disease segmentation in precision agriculture using optimal dimensionality reduction with fuzzy c-means clustering and deep learning,” *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 17, pp. 18 264–18 277, 2024.
- [6] Y. Kwon, S. Park, S. Park, and H. Lee, “Benchmarking of dimensionality reduction methods to capture drug response in transcriptome data,” *Scientific Reports*, vol. 15, 12 2025.
- [7] O. Hevdeli, E. Petrenko, and D. Aran, “Cellmentor: cell-type aware dimensionality reduction for single-cell rna-sequencing data,” *Nature Communications*, vol. 17, 12 2026.
- [8] S. Castellotti, I. Petrizzo, R. Arrighi, and E. Blini, “Dimensionality reduction techniques in pupillometry research: A primer for behavioral scientists,” *Behavior Research Methods*, vol. 57, 12 2025.
- [9] R. Zaheer, M. K. Hanif, M. U. Sarwar, and R. Talib, “Evaluating the effectiveness of dimensionality reduction on machine learning algorithms in time series forecasting,” *IEEE Access*, vol. 13, pp. 50 493–50 510, 2025.
- [10] M. Altin and A. Cakir, “Exploring the influence of dimensionality reduction on anomaly detection performance in multivariate time series,” *IEEE Access*, vol. 12, pp. 85 783–85 794, 2024.
- [11] B. Minnehan, N. Nagananda, and A. Savakis, “Grip-pca: Grassmann iterative p-norm principal component analysis,” *IEEE Open Journal of Signal Processing*, vol. 1, pp. 90–98, 2020.

- [12] T. S. Kumar and D. Kesavaraja, "Improving efficiency in smart grid monitoring using hybrid classification and dimensionality reduction," *Scientific Reports*, vol. 15, 12 2025.
- [13] Y. Yan, X. Le, T. Yang, and H. Yu, "Interpretable pca and svm-based leak detection algorithm for identifying water leakage using sar-derived moisture content and insar closure phase," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 17, pp. 15 136–15 147, 2024.
- [14] X. Sun, X. Wang, D. Cai, Z. Li, Y. Gao, and X. Wang, "Multivariate seawater quality prediction based on pca-rvm supported by edge computing towards smart ocean," *IEEE Access*, vol. 8, pp. 54 506–54 513, 2020.
- [15] H. Lee, G. I. Tombak, G. Park, and K. J. Kuchenbecker, "Perceptual space of algorithms for three-to-one dimensional reduction of realistic vibrations," *IEEE Transactions on Haptics*, vol. 15, pp. 521–534, 2022.
- [16] A. D. Jimenez-Narvaez, V. D. C. Vaca, J. J. Llor-Duque, I. R. A. Martin, I. G. Reyes-Chacon, P. Vizcaino, and M. E. Morocho-Cayamcela, "Predictive modeling for fetal health: A comparative study of pca, lda, and kpca for dimensionality reduction," *IEEE Access*, vol. 13, pp. 59 687–59 703, 2025.
- [17] J. Fang, S. Hu, and X. Ma, "Sar image de-noising via grouping-based pca and guided filter," *Journal of Systems Engineering and Electronics*, vol. 32, pp. 81–91, 2 2021.
- [18] D. Charalampidis, "Visualizing population structures by multidimensional scaling of smoothed pca-transformed data," *IEEE Access*, vol. 11, pp. 13 594–13 604, 2023.