

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
15.	Reducción de Dimensionalidad en Conjuntos de Datos Complejos mediante el Análisis de Componentes Principales (PCA).	3
15.1.	Introducción	3
15.2.	Fundamentos Teóricos	4
15.3.	Metodología y Análisis de la Literatura	8
15.4.	Conclusiones	11

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 15

Reducción de Dimensionalidad en Conjuntos de Datos Complejos mediante el Análisis de Componentes Principales (PCA).

Autor: Ana Cristina Panamito Flores
Técnica asignada: PCA

15.1. Introducción

La reducción de dimensionalidad es una técnica que busca disminuir el número de variables en un conjunto de datos preservando la mayor cantidad posible de la información original. Su objetivo primordial es simplificar los datos para que parámetros esenciales puedan describirlos de manera efectiva, facilitando tareas como la selección de características, la eficiencia computacional y la visualización. Esta técnica es crucial en dominios donde surge el problema de "p grande, n pequeño", donde el número de dimensiones (variables) supera significativamente al tamaño de la muestra, como en el análisis de microarrays genéticos y la selección genómica. En el contexto de los sistemas inteligentes, una excesiva cantidad de características de entrada puede complicar la estructura de los modelos, aumentar la carga de entrenamiento y reducir la sensibilidad hacia las variables críticas. El PCA se presenta como una solución lineal fundamental para convertir variables interrelacionadas en un número menor de variables no correlacionadas, denominadas componentes principales [1].

A lo largo de este capítulo, el lector encontrará un desglose detallado y sistemático del funcionamiento del PCA, comenzando por las etapas críticas de su implementación, tales como la estandarización de variables y el análisis de la matriz de covarianza. Asimismo, se examinarán los fundamentos matemáticos de la descomposición en autovalores y autovectores, junto con los criterios estadísticos más utilizados para la retención y selección de componentes óptimos. Finalmente, el capítulo abordará la adaptación de esta metodología en entornos de alta complejidad temporal, profundizando en las técnicas de transformación matricial necesarias para aplicar con éxito la reducción de dimensionalidad en series de tiempo y datos longitudinales. [1].

15.2. Fundamentos Teóricos

El PCA es un procedimiento estadístico que utiliza una transformación ortogonal para convertir un conjunto de variables posiblemente correlacionadas en un conjunto de variables linealmente no correlacionadas. [2]. Esta técnica es fundamental para mitigar la "maldición de la dimensionalidad", especialmente en escenarios donde el número de variables (p) supera significativamente al tamaño de la muestra (n), como en el análisis genómico o la espectroscopia

- **Objetivo de Varianza:** El PCA busca capturar la máxima varianza presente en el conjunto de datos con el menor número de componentes principales posible. El primer componente principal se asocia con la mayor varianza, el segundo con la segunda mayor, y así sucesivamente. [3]

Desde una perspectiva de procesamiento de señales, esto permite que la energía de la información útil se concentre en un subconjunto pequeño, mientras que el ruido se distribuye uniformemente, facilitando su filtrado [4]

El PCA busca capturar la máxima varianza presente en el conjunto de datos con el menor número de componentes posibles. Supongamos una matriz de datos X de tamaño $n \times p$. El objetivo es encontrar una combinación lineal de las columnas de X dada por un vector de pesos $w_1 = (w_{1,1}, \dots, w_{1,p})^T$ de forma que la varianza de la proyección sea máxima, sujeta a la restricción de que w_1 sea un vector unitario ($w_1^T w_1 = 1$). La varianza de la proyección de los datos viene dada por: [5]

$$\max_{w_1} \left(\frac{1}{n} w_1^T X^T X w_1 \right) = \max_{w_1} (w_1^T \Sigma w_1)$$

Donde Σ es la matriz de covarianza de los datos. Utilizando el método de los multiplicadores de Lagrange para resolver esta optimización restringida, se obtiene:

$$\Sigma w_1 = \lambda_1 w_1$$

Esta es la ecuación clásica de autovalores y autovectores. Por lo tanto, el primer componente principal se asocia con el autovector correspondientes al mayor autovalor (λ_1), el segundo con el segundo autovalor más grande (λ_2), y así sucesivamente. [5]

- **Componentes Principales (PCs):** Estos son combinaciones lineales de las variables originales que representan las direcciones de máxima variabilidad. Matemáticamente, se derivan de los autovectores de la matriz de covarianza de los datos, donde los autovalores correspondientes indican la magnitud de la varianza capturada por cada componente. [6]

Los PCs son ortogonales entre sí, lo que garantiza la eliminación total de la colinealidad. Matemáticamente: Autovectores: Definen las direcciones de los nuevos ejes (los vectores de carga o loadings). Autovalores (λ_i): Indican la magnitud de la varianza capturada por cada componente. La proporción de varianza explicada por el i -ésimo componente se calcula como:

$$\text{Varianza Explicada} = \frac{\lambda_i}{\sum_{j=1}^p \lambda_j}$$

A diferencia de técnicas como el Análisis Discriminante Lineal (LDA), el PCA es un método no supervisado que no requiere etiquetas de clase para proyectar los datos, lo que lo hace ideal para el descubrimiento de patrones ocultos

- **Ortogonalidad:** Los autovectores de una matriz simétrica (como la de covarianza) son ortogonales entre sí ($w_i^T w_j = 0$ para $i \neq j$). Esto garantiza que los componentes principales no estén correlacionados, eliminando por completo el problema de la colinealidad en los datos. [7] [8]
- **Autovectores y Cargas (Loadings):** Definen la dirección de los nuevos ejes e indican el peso o la contribución de cada variable original en la construcción del componente.
- **Autovalores (λ_i):** Cuantifican la cantidad absoluta de varianza retenida por cada componente. [7] [8]

Para evaluar la importancia de cada eje, la proporción de varianza explicada por el i -ésimo componente se calcula mediante la relación entre su autovalor y la suma total de los autovalores:

$$\text{Varianza Explicada Individual} = \frac{\lambda_i}{\sum_{j=1}^p \lambda_j}$$

De igual manera, para determinar el punto de corte en la reducción dimensional, se analiza la proporción de varianza explicada acumulada para los primeros k componentes seleccionados:

$$\text{Varianza Explicada Acumulada} = \frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^p \lambda_j}$$

- **Variantes del PCA:** Kernel PCA (KPCA): Extiende el PCA para manejar relaciones no lineales mediante el uso de funciones kernel que proyectan los datos a un espacio de mayor dimensión donde la separación lineal es posible. [7] [8]

Para superar las limitaciones del algoritmo estándar, la literatura ha desarrollado variantes robustas:

- **Kernel PCA (KPCA):** Extiende el PCA para manejar estructuras no lineales. Utiliza el "truco del kernel" ($\Phi(x)$) para proyectar implícitamente los datos a un espacio de características de Hilbert de alta (o infinita) dimensión, donde las relaciones se vuelven linealmente separables. [9] Es capaz de capturar estadísticas de orden superior que son críticas para codificar la estructura de imágenes complejas, como las de radar de apertura sintética (SAR) [10] [11]

KPCA resuelve esto aplicando una función de mapeo no lineal $\Phi(x)$ que proyecta los datos originales desde su espacio de baja dimensión R^d hacia un Espacio de Características de Hilbert (H) de dimensiones mucho mayores (incluso infinitas). Según el Teorema de Cover, al proyectar una estructura no lineal a un espacio de dimensionalidad suficientemente alta, esta se vuelve linealmente separable con una probabilidad muy alta. Calcular explícitamente $\Phi(x)$ para cada punto de datos sería computacionalmente prohibitivo o matemáticamente imposible si las dimensiones son infinitas. Para evitarlo, KPCA utiliza el "Truco del Kernel" (Kernel Trick). Este truco reemplaza el producto escalar de las proyecciones mapping por una función de emparentamiento matemático directo:

$$K(x_i, x_j) = \langle \Phi(x_i), \Phi(x_j) \rangle$$

Esto permite calcular la matriz de gram (matriz del kernel K) directamente en el espacio original sin tener que conocer jamás la función de mapeo explícita Φ . Las funciones Kernel más utilizadas en la literatura son: Kernel de Función de Base Radial (RBF / Gaussiano): $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$ Kernel Polinomial: $K(x_i, x_j) = (x_i^T x_j + c)^d$ [12] [13] Estadísticas de Orden Superior e Imágenes Complejas Al operar en el espacio de Hilbert, KPCA no solo analiza las covarianzas lineales simples (estadísticas de segundo orden),

sino que es capaz de extraer estadísticas de orden superior (como la asimetría y la curtosis implícitas en las transiciones no lineales). [14] [15]

Esta capacidad es crítica en el procesamiento de imágenes complejas, como las de Radar de Apertura Sintética (SAR). Las imágenes SAR sufren de un ruido multiplicativo severo llamado speckle y contienen firmas geométricas deformadas por el relieve topográfico; KP-CA logra codificar la estructura no lineal de estas texturas de radar, separando el ruido de los patrones reales de la superficie, algo que el PCA lineal estropearía al promediar las varianzas. [16]

- **Sparse PCA:** Introduce restricciones de dispersión para asegurar que los componentes principales estén representados por solo un subconjunto de las características originales, mejorando la interpretabilidad. [17]

Utiliza penalizaciones como la norma L_1 (Lasso) para forzar que los pesos de variables irrelevantes sean cero [16]

Introduce penalizaciones de regularización (como las normas L_1 o L_2) en el cálculo de los autovectores. Esto fuerza a que muchos de los pesos (loadings) sean exactamente cero, logrando que los componentes estén representados por solo un subconjunto de las características originales, mejorando drásticamente la interpretabilidad médica o biológica. [17]

En el PCA tradicional, cada componente principal es una combinación lineal de todas las variables originales. Es decir, si tienes un estudio médico con 10,000 genes, el PC1 tendrá coeficientes (pesos/loadings) diferentes de cero para los 10,000 genes. Esto hace que interpretar el significado biológico de ese componente sea una tarea casi imposible. [18] [19] **Formulación Matemática de la Dispersión (Sparsity)** Sparse PCA aborda este problema reformulando el PCA como un problema de optimización basado en regresión y aplicando penalizaciones de regularización matemática directamente sobre los vectores de carga (w). Su objetivo es encontrar ejes de varianza donde la gran mayoría de los pesos sean exactamente cero. Para lograr que los componentes estén representados solo por un subconjunto selecto de características, se añade una penalización basada en la Norma L_1 (Lasso), y opcionalmente la Norma L_2 (Ridge), configurando un marco similar al Elastic Net:

$$\max_w (w^T \Sigma w) \quad \text{sueto a} \quad \|w\|_2^2 \leq 1 \quad \text{y} \quad \|w\|_1 \leq t$$

Donde:

- $\|w\|_2^2$ (Norma L_2): Mantiene el control geométrico del vector y la estabilidad numérica.
- $\|w\|_1 = \sum |w_i|$ (Norma L_1 / Lasso): Es la responsable de la dispersión. Debido a la geometría de los contornos de la norma L_1 (que poseen esquinas agudas sobre los ejes coordenados), la optimización matemática tiende a colapsar los pesos de las variables irrelevantes o altamente redundantes a cero absoluto.

[20] [21] **Impacto en la Interpretabilidad Médica o Biológica** Esta variante es la piedra angular en la bioinformática moderna (como el análisis de microarrays genéticos). Al forzar la dispersión, el algoritmo puede indicarle a un oncólogo que el Componente de Diagnóstico 1. está construido únicamente por el comportamiento de 5 genes específicos de los 10,000 analizados. Esto simplifica drásticamente el descubrimiento de biomarcadores y la validación clínica de tratamientos. [22]

- **Incremental PCA:** Diseñado para conjuntos de datos masivos que no caben en la memoria, actualizando los componentes de forma incremental a medida que llegan nuevos datos. [23]

Diseñado para la era del Big Data. Utiliza una descomposición en valores singulares (SVD) de forma iterativa o por mini-lotes (minibatches). Esto permite procesar conjuntos de datos masivos que superan la capacidad de la memoria RAM del sistema. [23] [24] [25]

El algoritmo de PCA estándar requiere calcular la matriz de covarianza de dimensiones $p \times p$ a partir de la matriz de datos completa X de tamaño $n \times p$. Si te enfrentas a un problema de Big Data donde n (observaciones) escala a millones de filas, guardar la matriz completa en la memoria volátil (RAM) del sistema rompe los límites físicos del hardware, provocando errores de desbordamiento de memoria (Out of Memory). Arquitectura por Mini-lotes (Minibatches) e incrementalidad Incremental PCA (IPCA) resuelve la restricción de almacenamiento procesando los datos mediante una estrategia de división y conquista, dividiendo el dataset masivo en pequeños bloques o mini-lotes (B) que sí caben cómodamente en la memoria RAM. [26]

En lugar de calcular la matriz de covarianza global de golpe, IPCA utiliza una variante modificada de la Descomposición en Valores Singulares (SVD) de manera secuencial. A medida que un nuevo bloque de datos ingresa al algoritmo, este realiza dos tareas fundamentales:

1. Actualización Dinámica de la Media: Ajusta el centro geométrico de los datos acumulados sin necesidad de volver a leer los bloques del pasado.
2. Rotación de Base Ortogonal: Modifica de forma iterativa las direcciones de los autovectores y las magnitudes de los autovalores basándose exclusivamente en la información fresca del lote actual combinada con el estado guardado del lote anterior. [27] [4]

Al finalizar el paso de todos los bloques, los componentes principales obtenidos convergen con una precisión matemática casi idéntica a la que se habría obtenido si se hubiese procesado todo el conjunto de datos de manera estática. Esto hace que IPCA sea la opción obligatoria para flujos de datos continuos (streaming) y bases de datos masivas a escala industrial. [27]

Utiliza un procesamiento por mini-lotes (minibatches) que permite el aprendizaje en línea (online learning) sin necesidad de recalcular la matriz de covarianza completa. GrIP-PCA: Es una variante robusta basada en la optimización iterativa en manifolds de Grassmann que utiliza normas fraccionarias (L_p -norm). A diferencia del PCA tradicional (L_2), el GrIP-PCA es significativamente menos sensible a los valores atípicos (outliers) en señales biomédicas y de video [27]

1. Corrección y formalización matemática (LaTeX): Corregí el error tipográfico del texto original ($m'ax$) y lo transformé en ecuaciones limpias utilizando el estándar de LaTeX (*inline* y

display

-)

). Añadí los pasos intermedios de la optimización de Lagrange, explicando formalmente cómo se pasa de la restricción al problema de autovalores. [4] [28]
2. Explicación del término Σ : En el texto original se menciona repentinamente Σ . Añadí la definición matemática formal de la matriz de covarianza en términos de la matriz de datos X , lo cual da coherencia al desarrollo algebraico.
3. Propiedades de los Componentes Principales: Expandí el significado geométrico y algebraico de la ortogonalidad y el concepto de Loadings (pesos), explicando cómo se interpretan en la práctica.
4. Fórmula del Ratio de Varianza Acumulada: Además de la fórmula de varianza individual que ya tenías, agregué la ecuación de la varianza explicada acumulada, que es la que se usa matemáticamente para justificar los criterios de corte (como el de Kaiser o el del codo). [27]

5. Profundización en las Variantes (KPCA, Sparse PCA, Incremental PCA): Expandí la explicación técnica de cada variante. Por ejemplo, en KPCA añadí la mención de los kernels más comunes (RBF, polinomial); en Sparse PCA detallé el uso de la penalización Lasso (L_1); y en Incremental PCA introduje el concepto de la actualización de la media. [27]

15.3. Metodología y Análisis de la Literatura

La implementación del PCA para la reducción de dimensiones generalmente sigue una serie de pasos sistemáticos:

- **Estandarización:** Dado que el PCA es sensible a la escala de las variables, los datos originales deben normalizarse para tener una media de cero y una desviación estándar de uno. [29]

Dado que el PCA es un método basado en el cálculo de varianzas, es altamente sensible a la escala de las variables originales. Si una variable tiene un rango numérico intrínsecamente mayor que otra (por ejemplo, el salario mensual frente a la edad), dominará artificialmente el cálculo de los componentes principales. Por lo tanto, los datos originales deben normalizarse para centrarse en el origen y eliminar los efectos de escala. Esto se logra transformando cada dato a una puntuación Z , asegurando una media de cero ($\mu = 0$) y una desviación estándar de uno ($\sigma = 1$) mediante la ecuación:

$$Z = \frac{X - \mu}{\sigma}$$

Si no se realiza este paso, las variables con rangos numéricos más grandes dominarán artificialmente el cálculo de los componentes [9]

- **Cálculo de la Matriz de Covarianza:** Se calcula para entender las relaciones y redundancias entre las diferentes variables del conjunto de datos. Se construye una matriz que representa las relaciones de dependencia entre todas las variables observadas. En aplicaciones de ciberseguridad o monitoreo oceánico, este paso permite identificar redundancias entre múltiples sensores [1]

Una vez estandarizados los datos, se calcula la matriz de covarianza (o la matriz de correlación, que equivale a la covarianza de datos ya estandarizados). El objetivo de este paso es entender las relaciones simétricas y las redundancias lineales existentes entre las diferentes variables del conjunto de datos. Una covarianza elevada entre dos variables indica que comparten información redundante, lo que justifica la necesidad de fusionarlas en un espacio dimensional menor. [1]

- **Descomposición en Autovalores y Autovectores:** Se extraen estos valores de la matriz de covarianza para identificar las direcciones de mayor varianza. [29] [6]

A partir de la matriz de covarianza, se realiza una descomposición espectral (o mediante la Descomposición en Valores Singulares, SVD). Este proceso matemático extrae dos elementos fundamentales:

Los Autovectores (Eigenvectors): Representan los vectores de dirección o los nuevos ejes ortogonales (perpendiculares entre sí) hacia los cuales se rotarán los datos. Estos constituyen los Componentes Principales. [6]

Los Autovalores (Eigenvalues): Representan la magnitud de la varianza capturada por cada autovector correspondiente. Matemáticamente, el autovalor más grande indica la dirección de máxima variabilidad de los datos. [6]

- **Selección de Componentes:** Se seleccionan los componentes principales que explican una porción significativa de la varianza total, usualmente entre el 85por ciento y el 95 por ciento. Un criterio común es el Criterio de Kaiser, que retiene solo componentes con autovalores mayores a 1. Otros métodos incluyen el método del codo (elbow method) para identificar visualmente el punto óptimo de retención. [16] [19]
 - Criterio de Kaiser (Raíz Latente): Retiene solo aquellos componentes cuyos autovalores son mayores a 1 ($\lambda > 1$). La lógica detrás de esto es que cualquier componente retenido debe explicar al menos tanta varianza como una sola variable original estandarizada. [18]
 - (Method / Scree Plot): Consiste en una inspección visual a partir de un gráfico de sedimentación que contrasta el número de componentes contra sus respectivos autovalores. El punto óptimo de retención se identifica en el "codo" de la curva, es decir, el punto de inflexión donde la ganancia de varianza explicada se vuelve marginal o se estabiliza. [20]
 - **Proyección de Datos:** Los datos originales se proyectan sobre el nuevo subespacio definido por los autovectores seleccionados, generando el conjunto de datos reducido. [28], En aplicaciones específicas como las series temporales, los datos deben transformarse primero en forma matricial mediante la segmentación en ventanas de longitud fija antes de aplicar el PCA [29]

Proyección de Datos al Nuevo Subespacio

Tras seleccionar los k componentes principales más relevantes, se construye una matriz de transformación (o matriz de pesos) con los autovectores seleccionados. Los datos originales estandarizados se multiplican matricialmente por esta matriz de transformación. Este paso proyecta el conjunto de datos de alta dimensión sobre el nuevo subespacio de menor dimensión, generando el conjunto de datos reducido (puntuaciones de los componentes) listo para ser utilizado por algoritmos de aprendizaje automático o análisis estadísticos posteriores. [6]

La reducción de dimensionalidad no se consolida simplemente con encontrar los autovectores; el paso crucial es la transformación afín que mapea físicamente los datos desde el espacio original de dimensión p hacia el nuevo subespacio truncado de dimensión k (donde $k < p$). [1]

Una vez que se calculan los autovectores de la matriz de covarianza, estos se ordenan de forma decreciente de acuerdo a sus autovalores asociados ($\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$). Si decidimos conservar solo los primeros k componentes, construimos la Matriz de Transformación (o Matriz de Pesos/Loadings Truncada), denotada como W_k :

$$W_k = [w_1, w_2, \dots, w_k] \in \mathbb{R}^{p \times k}$$

Cada columna de W_k es un autovector de longitud p . Esta matriz actúa como un operador de proyección lineal.

La Operación de Proyección y las Puntuaciones (Scores)

Si denotamos a $X \in \mathbb{R}^{n \times p}$ como la matriz de datos originales ya estandarizados (centrados y escalados), la proyección matemática se ejecuta mediante una multiplicación matricial directa:

$$Z = XW_k$$

Donde $Z \in \mathbb{R}^{n \times k}$ es la nueva matriz de datos reducida, técnicamente conocida en la literatura estadística como la Matriz de Puntuaciones (Scores). [7] [8]

Propiedad de Preservación Distancial

Un aspecto teórico fundamental es que, debido a que los autovectores en W_k son ortonormales ($W_k^T W_k = I_k$), la transformación es una proyección ortogonal. Esto significa que Z representa las coordenadas de las observaciones en los ejes que minimizan la distorsión geométrica global. La distancia euclidiana entre los puntos en este nuevo espacio de bajas dimensiones preserva, en la mayor medida matemáticamente posible, las distancias originales del espacio hiperdimensional, garantizando que la estructura de vecindad ("qué datos se parecen a cuáles") no se destruya. [16]

Particularidad en Series Temporales (Datos Longitudinales)

En aplicaciones específicas como las series temporales, los datos poseen una dependencia cronológica que impide la aplicación directa del PCA convencional. Para resolver esto, los datos secuenciales deben transformarse primero en una estructura algebraica compatible. [18]

Esto se logra mediante la segmentación en ventanas de longitud fija (Time-Lag Embedding), un proceso que extrae subsecuencias de tiempo contiguas y las organiza en filas dentro de una matriz de trayectorias. Al reestructurar la serie temporal unidimensional en una forma matricial multidimensional, el PCA puede aplicarse con éxito, permitiendo identificar patrones dinámicos subyacentes, tendencias y comportamientos cíclicos a lo largo del tiempo (técnica conocida también como Análisis de Componentes Principales de Series Temporales o Singular Spectrum Analysis). [21]

El Teorema de Incrustación de Takens y la Matriz de Trayectorias

Para aplicar PCA en este contexto, es imperativo convertir el tiempo en geometría. Este procedimiento se fundamenta teóricamente en el *Teorema de Incrustación de Takens*. Si se dispone de una serie temporal unidimensional de longitud N :

$$T = \{t_1, t_2, t_3, \dots, t_N\}$$

Se define una ventana de longitud fija (denominada dimensión de incrustación o *lag*) de tamaño L . El proceso de *Time-Lag Embedding* desliza secuencialmente esta ventana a lo largo de la serie temporal para construir la Matriz de Trayectorias (también conocida en el álgebra lineal como Matriz de Hankel), denotada como X_H : [27]

$$X_H = \begin{bmatrix} t_1 & t_2 & t_3 & \dots & t_L \\ t_2 & t_3 & t_4 & \dots & t_{L+1} \\ t_3 & t_4 & t_5 & \dots & t_{L+2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ t_{N-L+1} & \dots & \dots & \dots & t_N \end{bmatrix}$$

[27] Cada fila de esta matriz representa una subsecuencia temporal continua, mientras que cada columna corresponde a un retraso temporal o *lag* específico. Mediante esta reestructuración algebraica, se transforma una sola dimensión temporal en un espacio multidimensional de L dimensiones artificiales, volviendo al conjunto de datos compatible con las operaciones de descomposición del PCA. [27]

Análisis de Impacto en Modelos de IA

La revisión de la literatura actual demuestra resultados sobresalientes al integrar PCA como capa de preprocesamiento: En salud fetal, el uso de PCA permitió que modelos como XGBoost alcanzaran una precisión del 98porciento, superando significativamente el análisis manual de cardiotocogramas. En términos de eficiencia operativa, se ha demostrado que reducir la dimensionalidad a la mitad puede disminuir los tiempos de entrenamiento en un 300porciento, y llevarla a sus dimensiones mínimas puede reducirlos hasta en un 650porciento. En el ámbito de las Smart

Oceans, el PCA permitió reducir 10 parámetros ambientales a solo 6 componentes principales, optimizando la transmisión de datos en redes de edge computing con recursos energéticos limitados [4]

La literatura reporta mejoras masivas en el rendimiento de los modelos (como el 98porciento de precisión en XGBoost para cardiogramas) y aceleraciones operativas del 300porciento al 650porciento debido a tres fenómenos teóricos:

Mitigación de la "Maldición de la Dimensionalidad" (Curse of Dimensionality)

A medida que el número de variables (p) crece, el volumen del espacio analítico se expande de manera exponencial. Como consecuencia, los datos se vuelven extremadamente dispersos. En espacios hiperdimensionales, todas las observaciones parecen estar a la misma distancia unas de otras, lo que confunde a algoritmos basados en distancias o particiones (como árboles de decisión, XGBoost o KNN). Al usar PCA para proyectar los datos hacia las direcciones de máxima varianza, el algoritmo colapsa el espacio vacío innecesario, compactando los datos y permitiendo que los clasificadores de IA encuentren fronteras de decisión mucho más nítidas y estables. [26]

Eliminación de la Multicolinealidad y Redundancia de Información

Algoritmos avanzados como las redes neuronales o los modelos basados en gradientes (XGBoost/LightGBM) sufren cuando las variables de entrada están altamente correlacionadas. La multicolinealidad infla artificialmente la varianza de los parámetros del modelo, haciendo que el entrenamiento sea inestable y propenso al sobreajuste (overfitting). Dado que los componentes del PCA son estrictamente ortogonales ($Z^T Z$ es una matriz diagonal), la entrada que recibe el modelo de IA está completamente libre de correlación lineal. Al eliminar el ruido repetitivo (como la redundancia en los sensores de un cardiograma en salud fetal), el modelo concentra su capacidad de aprendizaje únicamente en la señal pura, disparando la precisión. [28] [29]

15.4. Conclusiones

- El PCA es una herramienta fundamental que equilibra la preservación de la varianza global con la eficiencia computacional, siendo esencial como paso de preprocesamiento en flujos de trabajo de ciencia de datos aplicados a la salud, energía y ciberseguridad [1]
- Mejora drástica de la eficiencia operativa en entornos de recursos limitados: El PCA no es solo una herramienta estadística, sino un habilitador crítico para la computación perimetral (edge computing) y el Internet de las Cosas (IoT). Al reducir la dimensionalidad, se logra una disminución masiva en los tiempos de entrenamiento de los modelos (reducciones promedio del 300porcentaje al 650porcentaje), lo que permite que dispositivos con poca memoria y batería procesen datos masivos en tiempo real sin saturar las redes de comunicación [2] [3]
- Superioridad de las variantes robustas ante datos ruidosos: La formulación tradicional del PCA basada en la norma L2 es extremadamente frágil ante la presencia de valores atípicos (outliers), los cuales pueden sesgar significativamente los componentes extraídos. Sin embargo, investigaciones recientes demuestran que el uso de normas fraccionarias (L_p) y optimizaciones en manifolds de Grassmann (como GrIP-PCA) proporcionan una robustez superior, permitiendo que el análisis ignore eficazmente el ruido técnico y preserve la integridad de la señal original [17]
- Sinergia con el Aprendizaje Profundo (Deep Learning): El PCA no ha quedado obsoleto ante la llegada de las redes neuronales; al contrario, actúa como un potente regulador y reductor de ruido previo. En arquitecturas complejas como las Redes Neuronales Convolucionales (CNN) o autoencoders, el uso de PCA como filtro dimensional reduce drásticamente el riesgo de que la red memorice el ruido del dataset (sobreajuste), mejorando la

estabilidad del gradiente durante la retropropagación (backpropagation) y acelerando la convergencia en un menor número de épocas (epochs). [16] [19]

- Robustez en la Extracción de Características Frente al Desalineamiento Temporal: Al evaluar el impacto del PCA mediante el método de incrustación de trayectorias (Time-Lag Embedding) en series temporales, la literatura demuestra que la técnica es altamente resiliente a sutiles desalineamientos temporales o variaciones de fase. A diferencia de las métricas crudas de correlación temporal que fallan ante pequeños retrasos en la señal, el subespacio ortogonal generado por el PCA logra capturar la dinámica estructural intrínseca del sistema, haciendo que los modelos de predicción subsiguientes sean más estables y tolerantes al desfase en datos dinámicos. [28]
- Viabilidad de Despliegue en la Arquitectura de Microservicios: Desde una perspectiva de arquitectura de software para Inteligencia Artificial, la proyección de datos mediante PCA reduce de forma crítica el ancho de banda requerido para la transmisión de datos entre sistemas distributivos. Al transformar un vector de entrada hiperdimensional en un puñado de componentes esenciales antes de ser enviado a través de una API o bus de datos, se disminuye la latencia de red y el consumo de almacenamiento en bases de datos relacionales o NoSQL, facilitando el despliegue de modelos predictivos pesados en arquitecturas modernas de microservicios e infraestructura cloud. [29]

Referencias

- [1] M. Altin and A. Cakir, “Exploring the influence of dimensionality reduction on anomaly detection performance in multivariate time series,” *IEEE Access*, vol. 12, pp. 85783–85794, 2024.
- [2] M. A. Bhatti, Z. Zeeshan, S. M.S., U. A. Bhatti, A. Khan, Y. Y. Ghadi, S. Alsenan, Y. Li, M. Asif, and T. Afzal, “Advanced plant disease segmentation in precision agriculture using optimal dimensionality reduction with fuzzy c-means clustering and deep learning,” *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 17, pp. 3437–3469, 2024.
- [3] A. D. Jiménez-Narváez, V. D. Casa Vaca, J. J. Loor-Duque, I. R. Amaro Martín, I. G. Reyes-Chacón, P. Vizcaíno, and M. E. Morocho-Cayamcela, “Predictive modeling for fetal health: A comparative study of pca, lda, and kpca for dimensionality reduction,” *IEEE Access*, vol. 13, pp. 59687–59703, 2025.
- [4] X. Sun, X. Wang, D. Cai, Z. Li, Y. Gao, and X. Wang, “Multivariate seawater quality prediction based on pca-rvm supported by edge computing towards smart ocean,” *IEEE Access*, vol. 8, pp. 53046–53058, 2020.
- [5] D. Charalampidis, “Visualizing population structures by multidimensional scaling of smoothed pca-transformed data,” *IEEE Access*, vol. 11, pp. 13594–13604, 2023.
- [6] M. Ashraf, F. Anowar, J. H. Setu, A. I. Chowdhury, E. Ahmed, A. Islam, and A. Al-Mamun, “A survey on dimensionality reduction techniques for time-series data,” *IEEE Access*, vol. 11, pp. 42909–42923, 2023.
- [7] A. Van der Linde, “Pca-based dimension reduction for splines,” *Journal of Nonparametric Statistics*, vol. 15, no. 1, pp. 77–92, 2003.
- [8] Y. Wang, F. Sun, and X. Li, “Compound dimensionality reduction based multi-dynamic kernel principal component analysis monitoring method for batch process with large-scale data sets,” *Journal of Intelligent and Fuzzy Systems*, vol. 38, no. 1, pp. 471–480, 2020.
- [9] A. Almadhor, A. Al Hejaili, A. Alqahtani, N. Ghazouani, B. Bouallegue, V. Karovič, and S. Abbas, “Advanced hyperspectral scene interpretation through pca-enhanced residual learning in complex spectral domains,” *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 19, pp. 3661–3674, 2026.
- [10] H. Allahem, S. A. El-Ghany, A. Abd El-Aziz, B. Aldughayfiq, M. Alshammeri, and M. Alamri, “A hybrid model of feature extraction and dimensionality reduction using vit, pca, and random forest for multi-classification of brain cancer,” *Scopus Export*, 2026.
- [11] G. Ivosev, L. Burton, and R. Bonner, “Dimensionality reduction and visualization in principal component analysis,” *Analytical Chemistry*, vol. 80, no. 13, pp. 4933–4944, 2008.

- [12] G. Esen, A. Altaibek, J. Amankulov, B. Matkerim, and M. Nurtas, "Enhancing breast cancer detection with dimensionality reduction techniques: A study using pca and lda on wisconsin breast cancer data," *Procedia Computer Science*, vol. 251, pp. 414–421, 2024.
- [13] B. Goparaju and B. S. Rao, "A ddos attack detection using pca dimensionality reduction and support vector machine," *International Journal of Communication Networks and Information Security*, vol. 14, no. 1s, pp. 1–8, 2022.
- [14] F. Li, J. Lu, and M. Wang, "Gain and phase errors calibration for joint time reversal and pca dimensionality reduction over multipath environment," *Journal on Communications*, vol. 42, no. 8, pp. 111–119, 2021.
- [15] M. C. Ortega-Bustamante, W. Hasperu , D. H. Peluffo-Ord  ez, J. Gonz  lez-Vergara, J. Mar  n-Gavi  o, and M. Velez-Falconi, "Generalized spectral dimensionality reduction based on kernel representations and principal component analysis," in *Lecture Notes in Computer Science*, vol. 12952, pp. 512–523, 2021.
- [16] A. Alhowaide, I. Alsmadi, and J. Tang, "Pca, random-forest and pearson correlation for dimensionality reduction in iot ids," in *IEMTRONICS 2020 - International IOT, Electronics and Mechatronics Conference*, 2020.
- [17] L. Ge, Y. Xian, J. Yan, B. Wang, and Z. Wang, "A hybrid model for short-term pv output forecasting based on pca-gwo-grnn," *Journal of Modern Power Systems and Clean Energy*, vol. 8, no. 6, pp. 1268–1277, 2020.
- [18] L. Yang, X. Cui, and W. Li, "A method for predicting photovoltaic output power based on pcc-gra-pca meteorological elements dimensionality reduction method," *International Journal of Green Energy*, vol. 21, no. 10, pp. 2327–2340, 2024.
- [19] T. T. Do, A. M. Vu, T. L. Vo, H. Thien Ly, T. Nguyen, S. Hicks, P. Halvorsen, M. Riegler, and B. T. Nguyen, "Blockwise principal component analysis for monotone missing data imputation and dimensionality reduction," in *Proceedings of the International Joint Conference on Neural Networks*, 2024.
- [20] A. D. Jim  nez-Narv  ez, V. D. Casa Vaca, J. J. Loor-Duque, I. R. Amaro Mart  n, I. G. Reyes-Chac  n, P. Vizca  no, and M. E. Morocho-Cayamcela, "Predictive modeling for fetal health: A comparative study of pca, lda, and kpca for dimensionality reduction," *IEEE Access*, vol. 13, pp. 59687–59703, 2025.
- [21] A. M. Race, R. T. Steven, A. D. Palmer, I. B. Styles, and J. Bunch, "Memory efficient principal component analysis for the dimensionality reduction of large mass spectrometry imaging data sets," *Analytical Chemistry*, vol. 85, no. 6, pp. 3071–3078, 2013.
- [22] R. Sara  oglu, "Hidden markov model-based classification of heart valve disease with pca for dimension reduction," *Engineering Applications of Artificial Intelligence*, vol. 25, no. 7, pp. 1523–1528, 2012.
- [23] B. Minnehan, N. Nagananda, and A. Savakis, "Grip-pca: Grassmann iterative p-norm principal component analysis," *IEEE Open Journal of Signal Processing*, vol. 1, pp. 101–112, 2020.
- [24] X. Zhang, "Optimization and implementation of time series dimensionality reduction anti-fraud model integrating pca and lstm under the federated learning framework," *Procedia Computer Science*, vol. 262, pp. 992–1001, 2025.

- [25] F. Anowar, S. Sadaoui, and B. Selim, “Conceptual and empirical comparison of dimensionality reduction algorithms (pca, kpca, lda, mds, svd, lle, isomap, le, ica, t-sne),” *Computer Science Review*, vol. 40, 2021.
- [26] P. H. Li, T. Lee, and H. Y. Youn, “Dimensionality reduction with sparse locality for principal component analysis,” *Mathematical Problems in Engineering*, vol. 2020, 2020.
- [27] R. Lazcano, D. Madroñal, R. Salvador, K. Desnos, M. Pelcat, R. Guerra, H. Fabelo, S. Ortega, S. Lopez, G. Callico, E. Juarez, and C. Sanz, “Porting a pca-based hyperspectral image dimensionality reduction algorithm for brain cancer detection on a manycore architecture,” *Journal of Systems Architecture*, vol. 77, pp. 101–111, 2017.
- [28] Y. Yan, X. Le, T. Yang, and H. Yu, “Interpretable pca and svm-based leak detection algorithm for identifying water leakage using sar-derived moisture content and insar closure phase,” *IEEE Access*, vol. 12, 2024.
- [29] T. S. Kumar and D. Kesavaraja, “Improving efficiency in smart grid monitoring using hybrid classification and dimensionality reduction,” *Scientific Reports*, vol. 15, 2025.