

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
1.	Reducción de Dimensionalidad en Conjuntos de Datos Complejos mediante el Análisis de Componentes Principales (PCA).	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos	3
1.3.	Metodología y Análisis de la Literatura	4
1.4.	Conclusiones	4

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 1

Reducción de Dimensionalidad en Conjuntos de Datos Complejos mediante el Análisis de Componentes Principales (PCA).

Autor: Ana Cristina Panamito Flores
Técnica asignada: PCA

1.1. Introducción

La reducción de dimensionalidad es una técnica que busca disminuir el número de variables en un conjunto de datos preservando la mayor cantidad posible de la información original. Su objetivo primordial es simplificar los datos para que parámetros esenciales puedan describirlos de manera efectiva, facilitando tareas como la selección de características, la eficiencia computacional y la visualización. Esta técnica es crucial en dominios donde surge el problema de "p grande, n pequeño", donde el número de dimensiones (variables) supera significativamente al tamaño de la muestra, como en el análisis de microarrays genéticos y la selección genómica. En el contexto de los sistemas inteligentes, una excesiva cantidad de características de entrada puede complicar la estructura de los modelos, aumentar la carga de entrenamiento y reducir la sensibilidad hacia las variables críticas. El PCA se presenta como una solución lineal fundamental para convertir variables interrelacionadas en un número menor de variables no correlacionadas, denominadas componentes principales [1].

1.2. Fundamentos Teóricos

El PCA es un procedimiento estadístico que utiliza una transformación ortogonal para convertir un conjunto de variables posiblemente correlacionadas en un conjunto de variables linealmente no correlacionadas. [2].

Objetivo de Varianza: El PCA busca capturar la máxima varianza presente en el conjunto de datos con el menor número de componentes principales posible. El primer componente principal se asocia con la mayor varianza, el segundo con la segunda mayor, y así sucesivamente. [3]

Componentes Principales (PCs): Estos son combinaciones lineales de las variables originales que representan las direcciones de máxima variabilidad. Matemáticamente, se derivan de los autovectores de la matriz de covarianza de los datos, donde los autovalores correspondientes indican la magnitud de la varianza capturada por cada componente

Variantes del PCA: Kernel PCA (KPCA): Extiende el PCA para manejar relaciones no lineales mediante el uso de funciones kernel que proyectan los datos a un espacio de mayor dimensión donde la separación lineal es posible.

Sparse PCA: Introduce restricciones de dispersión para asegurar que los componentes principales estén representados por solo un subconjunto de las características originales, mejorando la interpretabilidad.

Incremental PCA: Diseñado para conjuntos de datos masivos que no caben en la memoria, actualizando los componentes de forma incremental a medida que llegan nuevos datos [3]:

1.3. Metodología y Análisis de la Literatura

La implementación del PCA para la reducción de dimensiones generalmente sigue una serie de pasos sistemáticos:

- Estandarización: Dado que el PCA es sensible a la escala de las variables, los datos originales deben normalizarse para tener una media de cero y una desviación estándar de uno.
- Cálculo de la Matriz de Covarianza: Se calcula para entender las relaciones y redundancias entre las diferentes variables del conjunto de datos.
- Descomposición en Autovalores y Autovectores: Se extraen estos valores de la matriz de covarianza para identificar las direcciones de mayor varianza.
- Selección de Componentes: Se seleccionan los componentes principales que explican una porción significativa de la varianza total, usualmente entre el 85por ciento y el 95 por ciento. Un criterio común es el Criterio de Kaiser, que retiene solo componentes con autovalores mayores a 1. Otros métodos incluyen el método del codo (elbow method) para identificar visualmente el punto óptimo de retención.
- Proyección de Datos: Los datos originales se proyectan sobre el nuevo subespacio definido por los autovectores seleccionados, generando el conjunto de datos reducido. [4], En aplicaciones específicas como las series temporales, los datos deben transformarse primero en forma matricial mediante la segmentación en ventanas de longitud fija antes de aplicar el PCA [5]

1.4. Conclusiones

El PCA es una herramienta fundamental que equilibra la preservación de la varianza global con la eficiencia computacional, siendo esencial como paso de preprocesamiento en flujos de trabajo de ciencia de datos aplicados a la salud, energía y ciberseguridad

Referencias

- [1] M. Altin and A. Cakir, “Exploring the influence of dimensionality reduction on anomaly detection performance in multivariate time series,” *IEEE Access*, vol. 12, pp. 85783–85794, 2024.
- [2] M. A. Bhatti, Z. Zeeshan, S. M.S., U. A. Bhatti, A. Khan, Y. Y. Ghadi, S. Alsenan, Y. Li, M. Asif, and T. Afzal, “Advanced plant disease segmentation in precision agriculture using optimal dimensionality reduction with fuzzy c-means clustering and deep learning,” *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 17, pp. 3437–3469, 2024.
- [3] A. D. Jiménez-Narváez, V. D. Casa Vaca, J. J. Loor-Duque, I. R. Amaro Martín, I. G. Reyes-Chacón, P. Vizcaíno, and M. E. Morocho-Cayamcela, “Predictive modeling for fetal health: A comparative study of pca, lda, and kpca for dimensionality reduction,” *IEEE Access*, vol. 13, pp. 59687–59703, 2025.
- [4] L. Chamba-Eras, *Metodología de la Investigación en Computación: Una Guía para el Diseño de Sistemas Inteligentes*. Loja, Ecuador: Editorial Universidad Nacional de Loja, 2026.
- [5] T. S. Kumar and D. Kesavaraja, “Improving efficiency in smart grid monitoring using hybrid classification and dimensionality reduction,” *Scientific Reports*, vol. 15, 2025.
- [6] M. A. Armas Ordoñez, “Modelado probabilístico estructurado en la informática médica e ingeniería clínica,” *IEEE Transactions on Artificial Intelligence*, vol. 6, no. 2, pp. 112–125, 2025.
- [7] L. Ge, Y. Xian, J. Yan, B. Wang, and Z. Wang, “A hybrid model for short-term pv output forecasting based on pca-gwo-grnn,” *Journal of Modern Power Systems and Clean Energy*, vol. 8, no. 6, pp. 1268–1277, 2020.
- [8] A. Almadhor, A. Al Hejaili, A. Alqahtani, N. Ghazouani, B. Bouallegue, V. Karovič, and S. Abbas, “Advanced hyperspectral scene interpretation through pca-enhanced residual learning in complex spectral domains,” *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 19, pp. 3661–3674, 2026.
- [9] M. Ashraf, F. Anowar, J. H. Setu, A. I. Chowdhury, E. Ahmed, A. Islam, and A. Al-Mamun, “A survey on dimensionality reduction techniques for time-series data,” *IEEE Access*, vol. 11, pp. 42909–42923, 2023.
- [10] B. Minnehan, N. Nagananda, and A. Savakis, “Grip-pca: Grassmann iterative p-norm principal component analysis,” *IEEE Open Journal of Signal Processing*, vol. 1, pp. 101–112, 2020.
- [11] Y. Yan, X. Le, T. Yang, and H. Yu, “Interpretable pca and svm-based leak detection algorithm for identifying water leakage using sar-derived moisture content and insar closure phase,” *IEEE Access*, vol. 12, 2024.

- [12] X. Sun, X. Wang, D. Cai, Z. Li, Y. Gao, and X. Wang, “Multivariate seawater quality prediction based on pca-rvm supported by edge computing towards smart ocean,” *IEEE Access*, vol. 8, pp. 53046–53058, 2020.
- [13] D. Charalampidis, “Visualizing population structures by multidimensional scaling of smoothed pca-transformed data,” *IEEE Access*, vol. 11, pp. 13594–13604, 2023.